实验 3: MapReduce 和 Spark 编程实验

171830046 陆天淳

基本需求:利用用户购物数据集,分析预测回头客。涉及数据预处理、存储、查询、排序、统计分析等数据处理全流程所涉及的各种典型应用场景, 涵盖 Hadoop、MapReduce、Spark、Hive、HBase 等系统和软件的安装和使用方法。

阶段一: MapReduce 编程

主要思路:将书中给的 WordCount.java 文件进行相应修改,完成对应要求。

完整代码见 WordCount.java

a. 数据读取

public void map(Object key, Text value, Context context)
 throws IOException, InterruptedException {
 String[] userinfo=value.toString().split(",");
 Text word = new Text();
 word.set(uerinfo[10]);
 String product=uerinfo[1];
 Integer a = Integer.parseInt(uerinfo);
 int m=a.intValue();
 IntWritable i = new IntWritable();

b. 数据统计

public static <K, V extends Comparable<? super V>> Map<K, V> sortDescend(Map<K, V> map) {
 List<Map.Entry<K, V>> list = new ArrayList<>(map.entrySet());
 Collections.sort(list, new Comparator<Map.Entry<K, V>>() {
 public int compare(Map.Entry<K, V> o1, Map.Entry<K, V> o2) {
 int compare = (o1.getValue()).compareTo(o2.getValue());
 return -compare:

1. 统计各省的双十一前十热门关注产品("点击+添加购物车+购买+关注"总量最多前 10 的产品)

完整数据见 guanzhu.txt

スIT(I / 洞田(L) 1位以(V) 且信(V) 16以(I I)							
上海市	67897上海市	783997上海市	636863上海市	1024557上海市	628774		
上海市	696384上海市	191499上海市	768758上海市	846404上海市	458784		
云南	67897云南	783997云南	636863云南	1024557云南	770668		
云南	628774云南	458784云南	846404云南	768758云南	94609		
内蒙古	67897内蒙古	783997内蒙古	636863内蒙古	1024557内蒙古	770668		
内蒙古	628774内蒙古	458784内蒙古	846404内蒙古	217788内蒙古	191499		
北京市	67897北京市	783997北京市	636863北京市	1024557北京市	770668		

2. 统计各省的双十一前十热门销售产品(购买最多前 10 的产品) *完整数据见 goumai.txt*

上海市	191499上海市	353560上海市	514725上海市	1059899上海市	713695
上海市	735931上海市	67897上海市	1039919上海市	944554上海市	107407
云南	191499云南	1059899云南	349999云南	1010145云南	655904
云南	48664云南	147751云南	496758云南	81360云南	181387

阶段二: Hive 操作

1. 把精简数据集导入到数据仓库 Hive 中,并对数据仓库 Hive 中的数据进行查询分析

2. 查询双 11 那天有多少人购买了商品

3. 查询双 11 那天男女买家购买商品的比例

```
hive> select count(1) from users where action =2
    ;
    ;
    very ID = root_20191220071009_c8679cf1-829e-42ef-ad4f-6c8248e2c0d6
    Total jobs = 1
    Launching Job 1 out of 1
    Number of reduce tasks determined at compile time: 1
    In order to change the average load for a reducer (in bytes):
        set hive.exec.reducers.bytes.per.reducer=<number>
    In order to limit the maximum number of reducers:
        set hive.exec.reducers.max=<number>
    In order to set a constant number of reducers:
        set mapreduce.job.reduces=<number>
    Starting Job = job_1576687152693_0001, Tracking URL = http://h01:8088/proxy/application_1576687152693_0001/
    Kill Command = /usr/local/hadoop/bin/mapred job -kill job_1576687152693_0001
    Hadoop job information for Stage-1: number of mappers: 1; number of reducers:
    :1
    2019-12-20 07:10:53,759 Stage-1 map = 0%, reduce = 0%
    2019-12-20 07:11:54,441 Stage-1 map = 0%, reduce = 0%, Cumulative CPU 12.53
```

女性用户:

```
Total MapReduce CPU Ilme Spent: 5 seconds 410 MSec
OK
39058
```

男性用户:

```
Total Mapkeduce Cro Time Spent. 3 Seconds 430 MSec
OK
38932
```

男女比为 0.997

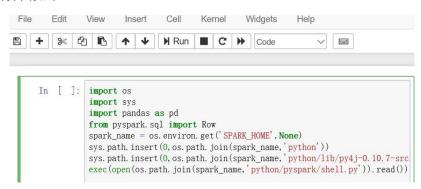
4. 查询双 11 那天浏览次数前十的品牌

阶段三: Spark 编程

在助教的镜像基础上配置了 pyspark,用 python 进行编程。

由于在 linux 中编程界面十分不友好,这里使用了 JUPYTER 进行编程。相关配置参考 https://www.jianshu.com/p/91365f343585

配置完成后界面如下:



首先将数据导入 dataframe。Dataframe 极大的方便了后续的数据处理。

1. 统计各省销售最好的产品类别前十(销售最多前 10 的产品类别)

```
action2 = record.select(record['action'] = '2')

province = record.select('province').distinct().collect()

for i in province:

temp=action2.filter(record0['province']==i[0])

temp0=temp0.groupby('cat_id').count()

temp=temp0.sort('count', ascending=False).limit(10).collect()

print(i[0]) //打印省份名称

print(temp)
```

北京市[Row(cat_id='656', count=131), Row(cat_id='602', count=111), Row(cat_id='1208', count=101), Row(cat_id='177', count=90 广东[Row(cat_id='656', count=132), Row(cat_id='1208', count=118), Row(cat_id='602', count=95), Row(cat_id='1401', count=87), 云南[Row(cat_id='1208', count=118), Row(cat_id='656', count=107), Row(cat_id='177', count=95), Row(cat_id='1142', count=82), Po蒙古[Row(cat_id='1208', count=118), Row(cat_id='656', count=105), Row(cat_id='662', count=92), Row(cat_id='602', count=86) 湖北[Row(cat_id='656', count=121), Row(cat_id='1208', count=112), Row(cat_id='1213', count=89), Row(cat_id='602', count=87),

完整数据见 spark1.txt

2. 统计各省的双十一前十热门销售产品(购买最多前 10 的产品)-- 和 MapReduce 作业 对比结果

```
for j in province:
    temp=action2.filter(record0['province']==j[0])
    temp0=temp.groupby('item_id').count()
    temp=temp0.sort('count', ascending=False).limit(10).collect()
    print(j[0])
    print(temp)[
```

北京市[Row(item_id='1059899', count=8), Row(item_id='191499', count=8), Row(item_id='514725', count=6), Row(item_id='9444' 广东[Row(item_id='181387', count=7), Row(item_id='926069', count=7), Row(item_id='110347', count=6), Row(item_id='1059899', coint=7), Row(item_id='191499', count=5), Row(item_id='655904', count=5), Row(item_id='4866', 内蒙古[Row(item_id='353560', count=8), Row(item_id='191499', count=8), Row(item_id='770668', count=6), Row(item_id='10398', count=6), Row(item_id='1059899', count=7), Row(item_id='191499', count=6), Row(item_id='1059899', count=7), Row(item_id='349999', count=7), Row(item_id='353560', count=7), Row(item_id='1059899', count=7), Row(item_id='191499', count=8), Row(item_id='353560', count=7), Row(item_id='353560', count=8), Row(item_id='191499', count=8), Row(item_id='353560', count=9), Row(item_id='514725', count=8), Row(item_id='514725', count=8), Row(item_id='353560', count=9), Row(item_id='514725', count=8), Row(item_id='514725', count=8), Row(ite

完整数据见 spark2.txt

与 mapreduce 对比:

上海市	191499上海市	353560上海市	514725上海市	1059899上海市	713695
上海市	735931上海市	67897上海市	1039919上海市	944554上海市	107407
云南	191499云南	1059899云南	349999云南	1010145云南	655904
云南	48664云南	147751云南	496758云南	81360云南	181387

排序有些许差异, 结果一致。

3. 查询双 11 那天浏览次数前十的品牌 -- 和 Hive 作业对比结果

```
action0 = record.filter(record['action'] == '0')
result0 = action0.groupby('brand_id').count()
result = result0.sort('count', ascending=False).limit(10).collect()
print(result)
```

[Row(brand_id='1360', count=49151), Row(brand_id='3738', count=10130), Row(brand_id='82', count=9719), Row(brand_id='1446', count=9426), Row(brand_id='6215', count=856 8), Row(brand_id='1214', count=8470), Row(brand_id='537 6', count=8282), Row(brand_id='2276', count=7990), Row(b

与 hive 对比:

结果一致。

阶段四:数据挖掘

针对预处理后的训练集和测试集,基于 MapReduce 或 Spark MLlib 编写程序预测回头客。

基本思路:采用支持向量机 SVM 分类器预测回头客。原本准备使用 pyspark 中的 ML 库进行预测,但是由于对这个库一无所知,出现了太多 bug······,转为使用 scala 进行编写。在程序的最后阶段数据保存阶段,多次 saveAsTextFile 失败以后转为打印所有数据,由于 ubuntu命令行界面只能显示一部分数据,故手动复制黏贴了后面的数据到 out.txt 中,下面只展示了前 10 个数据。

1. Spark 启动

2. 在 spark-shell 中导入 SVM 需要的包

```
scala> import org.apache.spark.SparkConf import org.apache.spark.SparkConf scala> import org.apache.spark.SparkContext import org.apache.spark.SparkContext scala> import org.apache.spark.mllib.regression.LabeledPoint import org.apache.spark.mllib.regression.LabeledPoint scala> import org.apache.spark.mllib.linalg.{Vectors, Vector} import org.apache.spark.mllib.linalg.{Vectors, Vector} scala> import org.apache.spark.mllib.linalg.{Vectors, Vector} scala> import org.apache.spark.mllib.classification.{SVMModel, SVMWithSGD} import org.apache.spark.mllib.classification.{SVMModel, SVMWithSGD} scala> import org.apache.spark.mllib.evaluation.BinaryClassificationMetrics import org.apache.spark.mllib.evaluation.BinaryClassificationMetrics scala> import java.util.Properties import java.util.Properties
'scala> import org.apache.spark.sql.types._
import org.apache.spark.sql.types._
import org.apache.spark.sql.types._
scala> import org.apache.spark.sql.types._
import org.apache.spark.sql.types._
```

3. 读取数据

4. 构造 SVM 模型

5. 设置迭代次数并训练

6. 模型评估

```
scala> model.clearThreshold()
res0: model.type = org.apache.spark.mllib.classification.SVMModel: intercept =
0.0, numFeatures = 3, numClasses = 2, threshold = None
```

7. 数据保存与展示